寵物/兔子行為識別模型提升方案

現狀問題

一句話：訓練數據和部署環境不一樣，模型骨架也太小了。

- 訓練數據主要來自手持/網路影片，部署在固定攝影機畫面——視角、光線、背景完全不同，模型到現場「水土不服」
- 當前模型（RepViT-M1）是**為低功耗設備設計的輕量級架構**，PC 端算力相对充裕，但模型能力沒充分利用

改進方案：雙線推進

線一：數據

做什麼： 從深水埗和 hkbr 兩個實際部署點回收真實攝影機影片，補充到訓練集。

重點加強兩個類別：

貓狗數據集當前標籤分布：

類別	訓練集	驗證集	合計
Other（移動/休息/跳躍）	3117	779	3896
Eat（進食）	745	137	882
Drink（飲水）	705	126	831

兔子數據集當前標籤分布：

類別	訓練集	驗證集	合計
Eating（進食）	1229	300	1529
Moving（移動）	756	186	942
Resting（休息）	899	220	1119
Drinking（飲水）	984	239	1223

貓狗Eat 和 Drink 兩個類別在實際場景中最關鍵，但在兩個數據集中樣本量都相對偏少，且現有數據以手持/網路影片為主，與攝影機實景差距最大。補充重點集中在這兩類。

目標數據量： 貓狗的 Eat + Drink 各從現有約 700 條補充至 1500 條以上；兔子的 Eating + Drinking 在現有基礎上各追加約 500-800 條真實攝影機數據

同時給舊數據做處理： 模擬攝影機畫質（運動模糊、解析度降低、色彩偏移），讓舊數據風格更貼近部署場景。

耗時： 數據採集和標註約 1-2 週（加interns），數據增強改造1-2天能做完

線二：模型 —— 「換粗一點的骨架」

做什麼： 把模型從 RepViT-M1 升級到 RepViT-M1.5，參數量翻倍（~5M → ~13M），但同屬一個架構家族，代碼改動小。

額外加一個優化： 給 backbone 加 TSM（可以理解成讓模型在看單幀的同時，自動參考前後幾幀的運動資訊），對識別「往前倒水」「歪頭吃食」這類動作更有幫助。

耗時： 模型改造約 2 天，重新訓練約 4-5 天（含調參迭代）

時間線

階段	內容	預估時間
第 1 週	數據回收 + 模型升級改造並行跑	3-5 天
第 1-2 週	用舊數據先訓練 M1.5 模型（不等新數據）	2-3 天
第 2 週	新數據到位後，合併訓練最終版	3-5 天
第 2-3 週	部署驗證、根據線上回饋微調	3-5 天

整體 1-3 週完成各階段改造和驗證。

後續擴展

PC 端模型穩定後，可以用 PC 版模型作為教師（Teacher），重新蒸餾一個更小的版本來部署到低功耗設備（SoC），不需要重新採集數據。

需要的資源

1. 深水埗和 hkbr 部署點的錄製影片回撈
2. eating / drinking 類別的人工標註或半自動標註
3. 一台帶 GPU 的訓練機器（現有即可）